


## Laboratorio 15: MongoDB Distribuido vs Citus - Análisis Comparativo

**Objetivo:** Implementar y comparar búsqueda textual distribuida en MongoDB (Sharding) y Citus (PostgreSQL), utilizando el dataset de noticias sobre Milei. Se analizará el rendimiento, estrategias de particionamiento y procesamiento interno de cada sistema.

### Parte I: Sharding en MongoDB (8 pts)



**Dataset:** [News Headlines About President Milei](#) — campos: `news_paper`, `section`, `title`, `summary`, `published`, `link`, `tags`

### Tareas

1. Configurar con Docker un cluster de Sharding con 2 shards; conectar con MongoDB Compass y ejecutar `sh.status()`.
2. Descargar, explorar y limpiar el dataset (valores nulos, inconsistencias, normalización del campo `section`); cargar **todos los datos** en la colección `milei_news` usando `pymongo`.
3. Habilitar sharding sobre `milei_news` usando `section` como shard key; elegir entre estrategia **hash** o **rango** según la distribución del dataset.
4. Crear los siguientes índices:
  - o Índice simple sobre `published`

- Índice hash sobre `news_paper`
- Índice de texto sobre `title` y `summary`

5. Implementar las **5 consultas de referencia** (ver sección al final) y ejecutar `explain("executionStats")` en cada una.
6. Registrar tiempos de ejecución de las 5 consultas en una tabla pandas.


## Preguntas de Evaluación

Responder en el informe con la evidencia indicada.

| #  | Pregunta                                                                                                                                | Evidencia requerida                                                           | Pts |
|----|-----------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|-----|
| P1 | ¿Cómo quedó configurado el cluster?                                                                                                     | Screenshot <code>sh.status()</code> y MongoDB Compass                         | 1   |
| P2 | ¿Qué limpieza fue necesaria y cómo quedó el dataset?                                                                                    | Tabla estadísticas (registros, nulos, distribución de <code>section</code> )  | 1   |
| P3 | ¿Qué estrategia de partición se eligió y por qué? ¿El balance de chunks es adecuado?                                                    | Análisis de frecuencia de secciones + screenshot distribución de chunks       | 2   |
| P4 | ¿Cómo funciona el índice de texto en MongoDB?<br>¿Usa índice invertido, TF-IDF, stemming? ¿Cómo se distribuye la búsqueda entre shards? | Extract de <code>explain("executionStats")</code> + investigación documentada | 2   |
| P5 | ¿Cuáles son los tiempos de Q1–Q5? ¿Qué tipo de consulta es más eficiente en MongoDB?                                                    | Tabla pandas con tiempos de ejecución                                         | 2   |

## Parte II: Citus en PostgreSQL (8 pts)

Citus extiende PostgreSQL para crear sistemas distribuidos mediante particionamiento horizontal. Soporta índices GIN para búsqueda textual eficiente.



## Tareas

1. Configurar cluster Citus con Docker usando **2 workers**; crear base de datos `news_analysis_pg` y habilitar la extensión Citus.
2. Diseñar esquema relacional de tabla `milei_news` y cargar los mismos datos del dataset usando `psycopg2` o `sqlalchemy`.
3. Convertir la tabla en distribuida usando `section` como clave de distribución; elegir estrategia **hash** o **rango** y verificar distribución entre workers.
4. Crear los siguientes índices:
  - o Índice GIN sobre `to_tsvector('spanish', title || ' ' || summary)`
  - o Índice B+Tree sobre `published`
  - o Índice Hash sobre `news_paper`
5. Implementar las **5 consultas de referencia** equivalentes en SQL (usando `to_tsvector`, `to_tsquery`, `@@`, `ts_rank`) y ejecutar `EXPLAIN ANALYZE` en cada una.
6. Registrar tiempos de ejecución de las 5 consultas en una tabla pandas.

## Preguntas de Evaluación

| #   | Pregunta                                                                                                                                       | Evidencia requerida                                                                 | Pts |
|-----|------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-----|
| P6  | ¿Cómo quedó configurado el cluster Citus?                                                                                                      | Screenshot de workers activos y configuración                                       | 1   |
| P7  | ¿Qué estrategia de distribución se eligió y cómo quedó la distribución de shards entre workers?                                                | Justificación + screenshot distribución                                             | 1   |
| P8  | ¿Cómo funciona el índice GIN para búsqueda textual?<br>¿ <code>ts_rank</code> usa TF-IDF? ¿Cómo se compara con el índice invertido de MongoDB? | Extract de <code>EXPLAIN ANALYZE</code> + investigación documentada                 | 2   |
| P9  | ¿Cuáles son los tiempos de Q1–Q5 en Citus? ¿Qué tipo de consulta es más eficiente?                                                             | Tabla pandas con tiempos de ejecución                                               | 2   |
| P10 | ¿Cómo Citus distribuye y paraleliza cada tipo de consulta? ¿Se detecta overhead de coordinación?                                               | Extracts de <code>EXPLAIN ANALYZE</code> con nodos <code>Custom Scan (Citus)</code> | 2   |

## Parte III: Comparación y Conclusiones (4 pts)

### Preguntas de Evaluación

| #   | Pregunta                                                                                                                                                                                            | Evidencia requerida                                                                                                            | Pts |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------|-----|
| P11 | ¿Cuál sistema es más eficiente para búsquedas textuales (Q1, Q2), ordenamiento (Q3) y agregaciones (Q4, Q5)? ¿Cómo afecta el particionamiento por <code>section</code> a Q4 vs. Q5 en cada sistema? | Tabla/gráfico comparativo de tiempos Q1–Q5 en ambos sistemas; análisis por tipo de operación                                   | 2   |
| P12 | ¿Cuál sistema es más apropiado para un sistema de análisis de noticias con requisitos mixtos?                                                                                                       | Síntesis técnica (modelo de datos, indexación, paralelización) + recomendación justificada con evidencia empírica + trade-offs | 2   |

# Consultas de Referencia

Las siguientes consultas deben implementarse en **ambos sistemas** (MongoDB y Citus):

| #  | Tipo                                    | Descripción                                                                                                                 |
|----|-----------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| Q1 | Búsqueda textual                        | Buscar noticias que contengan múltiples términos (ej: "dólar inflación"), ordenadas por relevancia descendente              |
| Q2 | Búsqueda con exclusión                  | Buscar noticias que contengan un término pero excluyan otro (ej: "Milei" sin "Twitter"), ordenadas por fecha de publicación |
| Q3 | Ordenamiento simple                     | Recuperar las 10 noticias más recientes, ordenadas por fecha de publicación descendente                                     |
| Q4 | Agregación por shard key                | Contar noticias agrupadas por <code>section</code> , ordenadas por cantidad descendente                                     |
| Q5 | Agregación por atributo no particionado | Contar noticias agrupadas por <code>news_paper</code> , ordenadas por cantidad descendente                                  |

## Entregables

**Formato:** Informe PDF estructurado con: portada, metodología, resultados por sistema, comparación y conclusiones.

**Archivos requeridos:**

1. **Informe PDF** — responde las preguntas P1–P12 con evidencia en el orden indicado
2. **Notebooks Jupyter** — uno por sistema, con código documentado y salidas visibles
3. **Scripts** — `docker-compose.yml` , carga de datos, creación de índices
4. **Screenshots** — configuraciones de cluster, distribución de datos, extractos de `explain / ANALYZE`